Università degli Studi di Milano Bicocca
Dipartimento di Informatica, Sistemistica e Comunicazione
Corso di laurea in Informatica

Letter Recognition

Barbera Matteo – 887512
Pellegatta Luca – 885966
Villa Emma – 885906

Introduzione al dataset

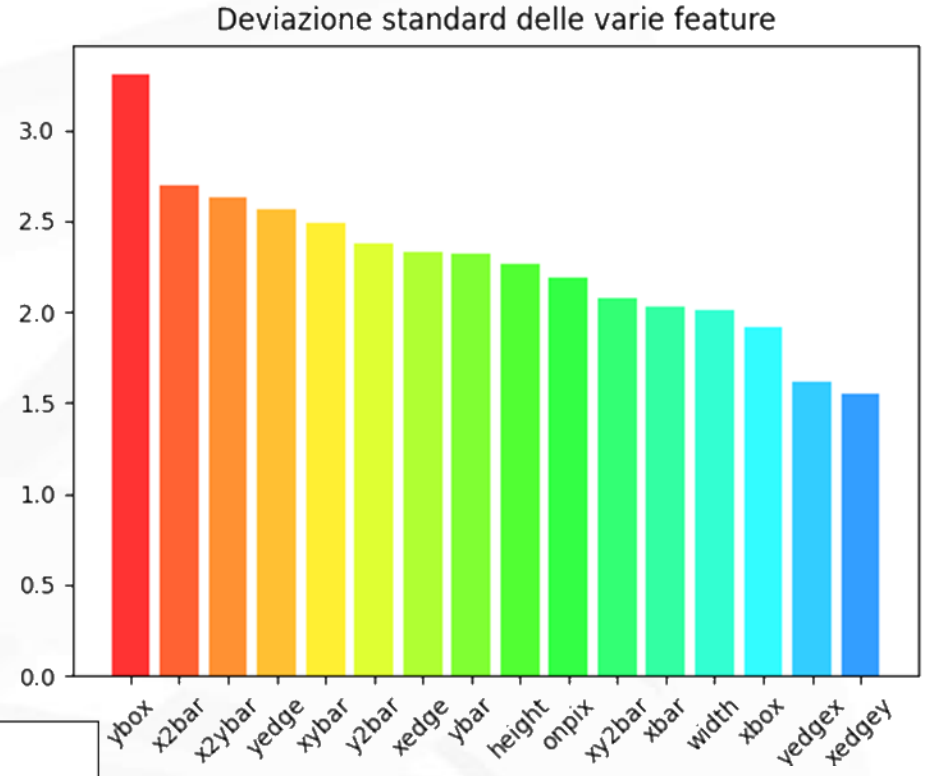
Il dataset analizzato contiene feature numeriche dei campioni di immagini delle lettere maiuscole latine scritte a mano.

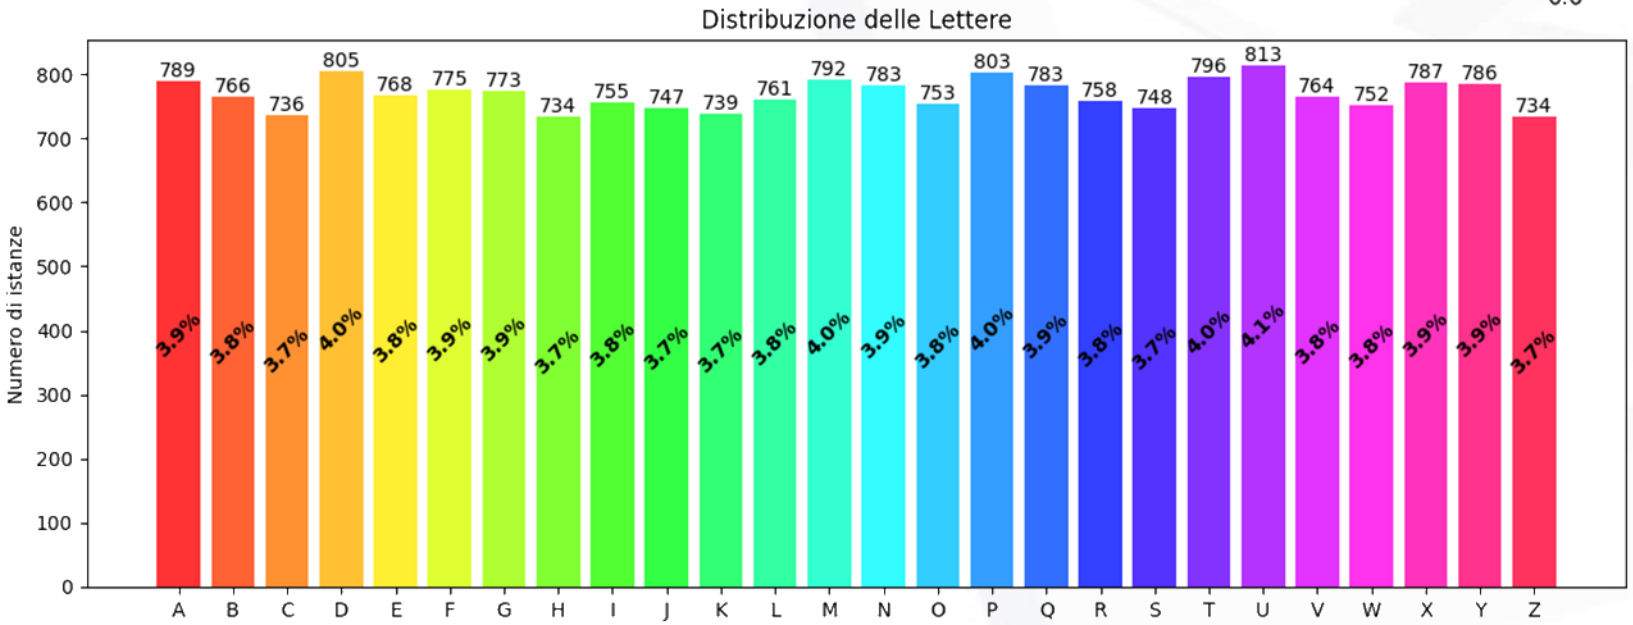
Il dataset presenta 20.000 esempi, caratterizzati da 16 feature più la colonna della label.

x-box	y-box	width	high
onpix	x-bar	y-bar	x2bar
y2bar	xybar	x2ybr	xy2br
X-ege	xegvy	y-ege	yegvx

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

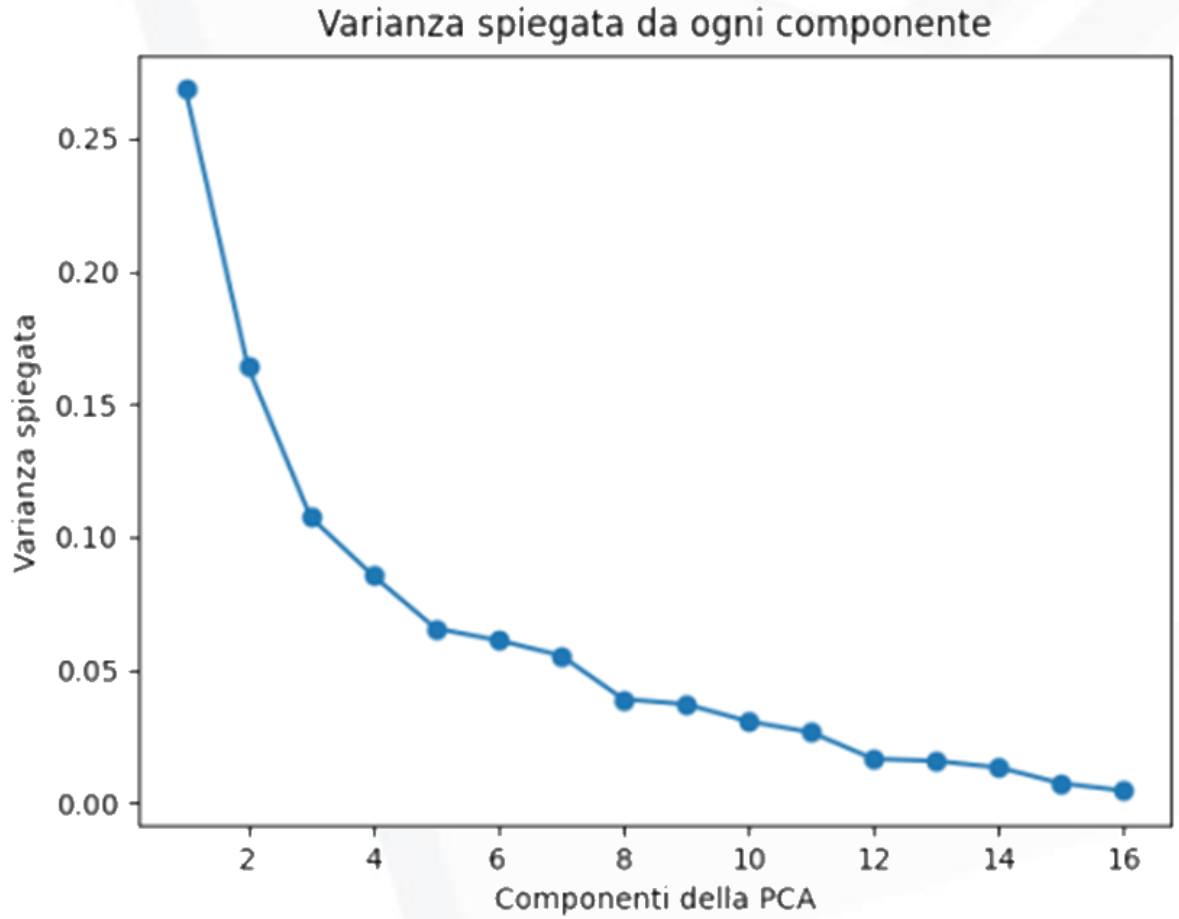
Analisi esplorativa





UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Analisi esplorativa:
analisi delle componenti principali



Reti neurali

Strati

La nostra rete neurale è composta da 4 layer densi di dimensione (16, 256, 128, 26).

Funzione di attivazione

Abbiamo utilizzato ReLu per gli strati di input e hidden e Softmax per lo strato di output.

Aggiornamento dei pesi

Abbiamo deciso di utilizzare Adam, un algoritmo stocastico basato su Gradient Descent, con un learning rate di $8 \cdot 10^{-5}$

Funzione di loss

La funzione utilizzata è la categorical_crossentropy

Accuracy: 95.17%
Loss: 15.81%.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

SVM

Accuracy: 85%

Kernel utilizzato

Abbiamo utilizzato un kernel lineare.

Iperparametro C

Il valore di regolarizzazione è stato impostato C = 1.0

Comportamento atteso

Non ci aspettiamo di ottenere risultati ottimi in quanto un kernel lineare non sarebbe il più appropriato poiché una separazione meramente lineare potrebbe non riuscire a discriminare bene le varie classi

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

K-Fold Cross Validation su Reti Neurali

K partizioni

Abbiamo scelto un valore di k=5, ottenendo 5 partizioni di dimensione 4.000.

Early stopping

Con valore di patience = 3. L'apprendimento termina quando il valore della loss, nelle ultime tre epoche, non decresce abbastanza.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

GridSearch Cross Validation su SVM

Kernel utilizzati

Abbiamo impostato 2 kernel possibili: RBF e Poly

Iperparametro C

Abbiamo definito 21 possibili valori per C. Partendo da $C_0 = 0.1$

$$C_i = C_{i-1} \cdot {}^{3}/_{2}$$

Gamma

Necessario nel caso in cui si utilizza un kernel RBF.
Abbiamo impostato solo 3 possibili valori per Gamma: 0,1 , 1 e 10

K partizioni

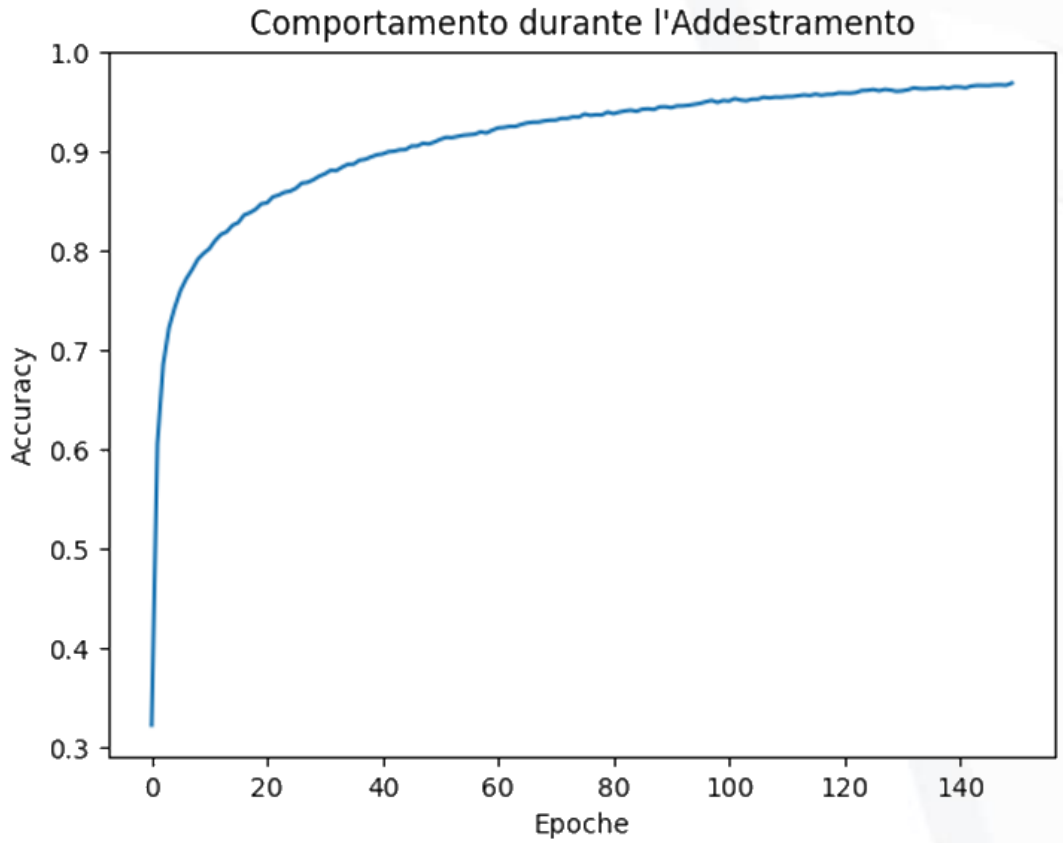
Abbiamo scelto un valore di k=5, ottenendo 5 partizioni di dimensione 4.000.

Kernel: RBF
C: 12.974
gamma: 0.1

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Risultati – Reti neurali

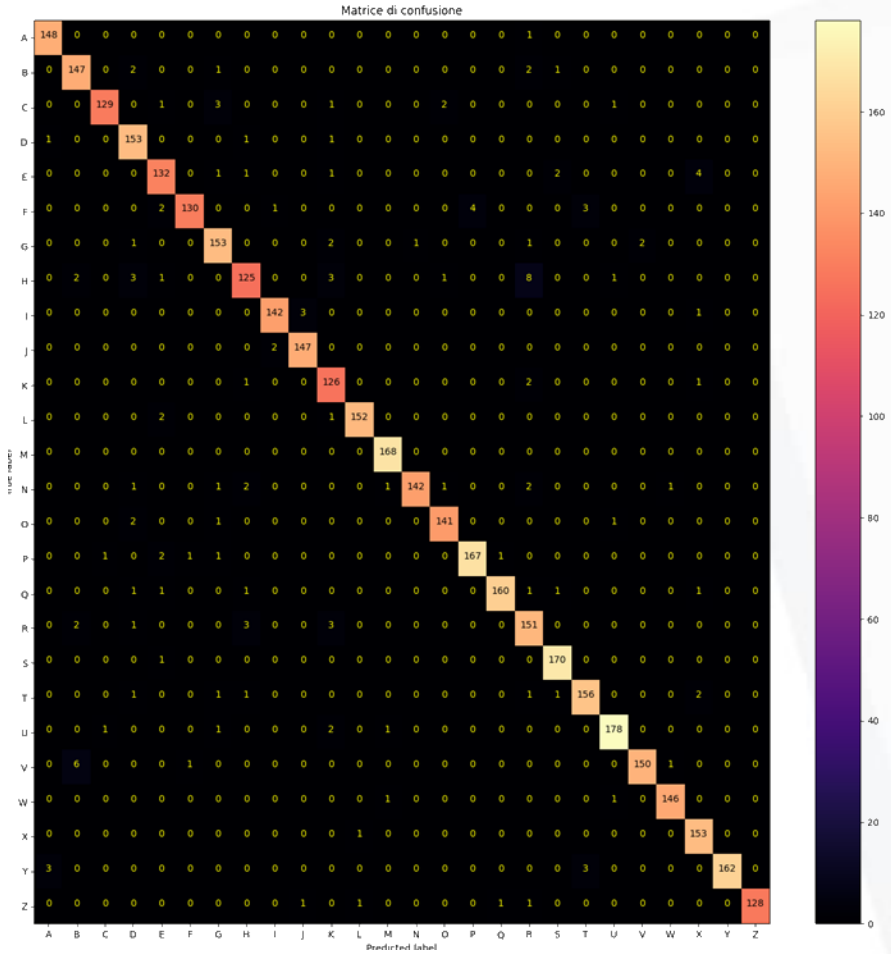
Accuracy: 95%

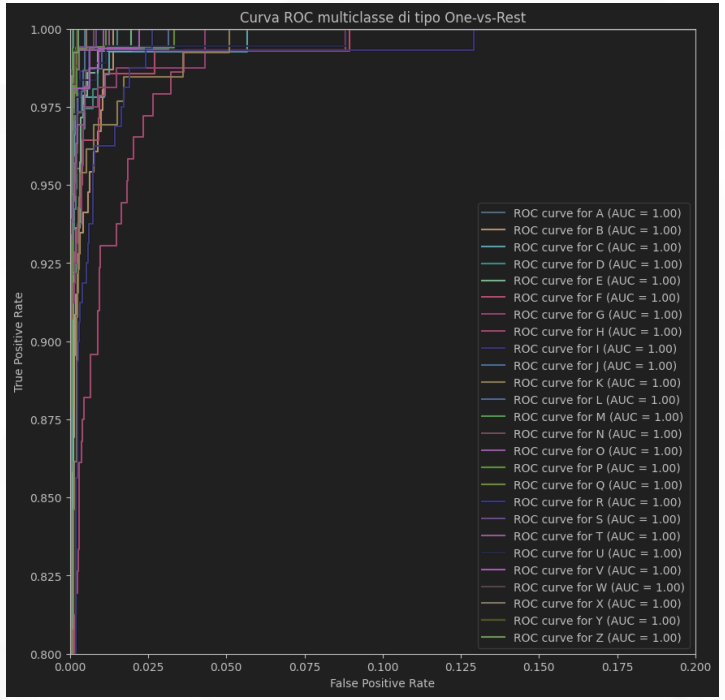


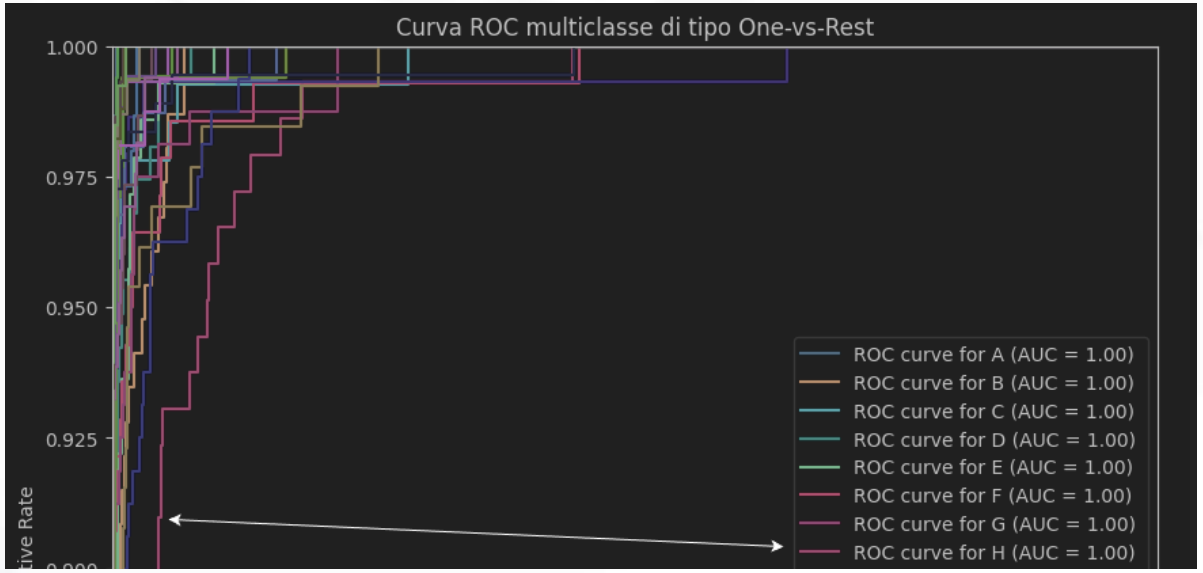
Precision	0.9588
Recall	0.9585
F-score	0.9584

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Risultati – Reti neurali







Risultati – SVM

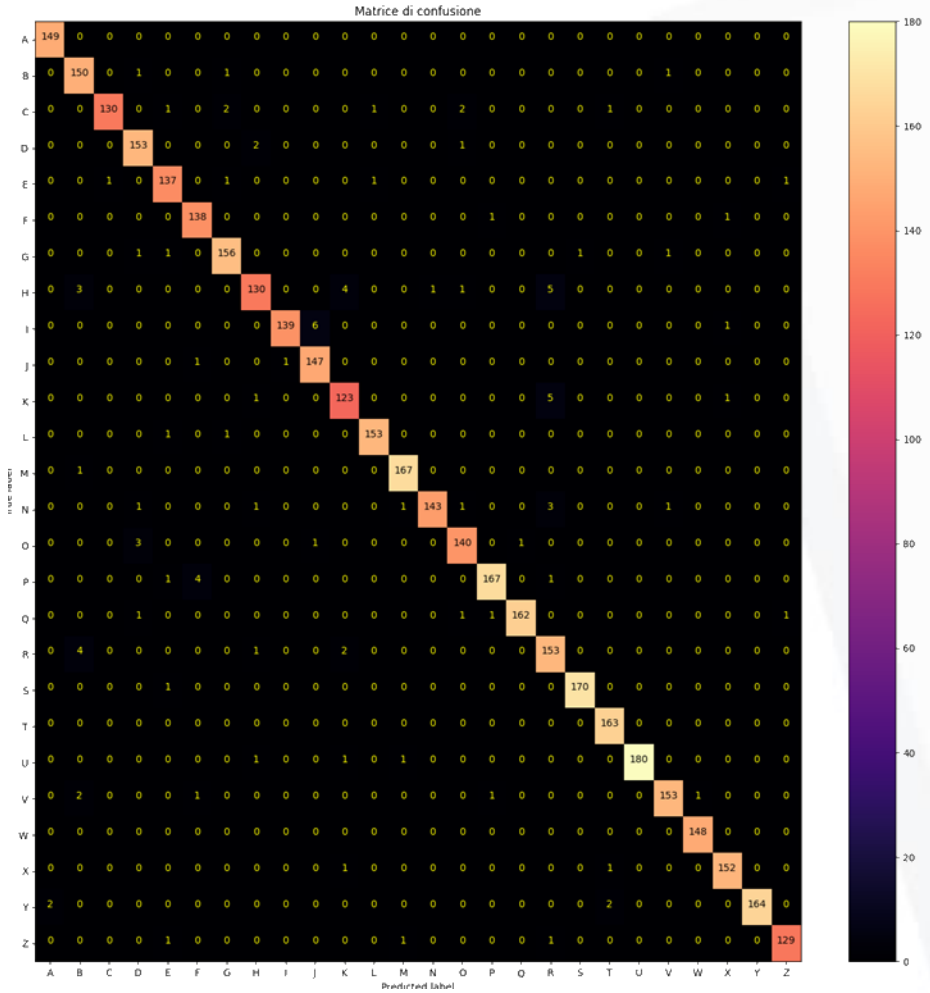
Accuracy: 97%

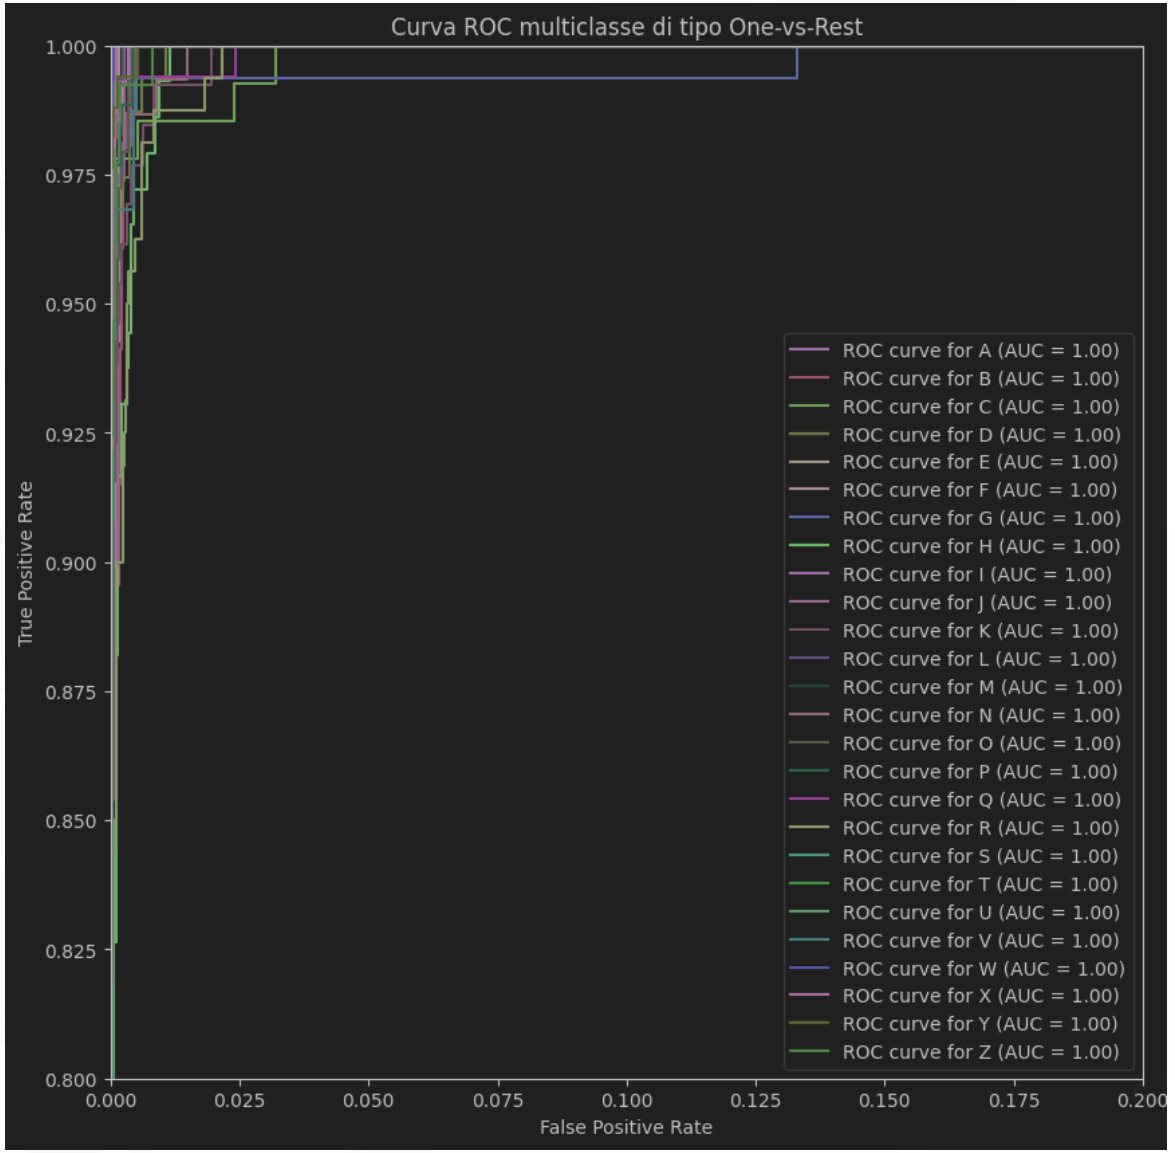
Precision	0.9744
Recall	0.9740
F-score	0.9740

La SVM si rivela particolarmente adatta per la risoluzione di questo problema dati gli alti indici di valutazione.

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Risultati – SVM





UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA

Conclusioni

Entrambi i modelli di classificazione sono riusciti a classificare correttamente dati mai osservati, non andando però in overfitting.

Reti neurali

Accuracy: 95%

Computazione:

- K-Fold Cross Validation: 300 secondi
- Early stopping: 223 secondi

SVM

Accuracy: 97%

Computazione:

- Stratified K-Fold: 3877 secondi

Il miglior modello, in termini di accuratezza di classificazione è la SVM

Il miglior modello, in termini computazionali è la Rete Neurale

UNIVERSITÀ DEGLI STUDI DI MILANO BICOCCA